



Radar de Gastos da Cota Parlamentar: Priorização Estatística com Triagem por LLM e Validação Humana

Um pipeline CRISP-DM reproduzível para priorizar — nunca acusar —
despesas atípicas da CEAP

Alisson Machado — MBA AI Applications

Julho de 2026

Versão 1.0

Resumo. A Cota para o Exercício da Atividade Parlamentar (CEAP) soma 284.845 despesas e R\$ 345.090.001,79 em 19 meses (jan/2025 a jul/2026) — volume humanamente inaudível um lançamento de cada vez. Este trabalho constrói um pipeline CRISP-DM completo que (i) detecta padrões de gasto atípicos com três métodos estatísticos independentes e robustos (mediana/MAD, HHI de concentração de fornecedor), reduzindo 601 deputados a 253 sinalizados por 2+ métodos e 26 pelos 3 simultaneamente; (ii) usa um LLM (Claude, via API Anthropic) com saída estruturada via Pydantic para classificar severidade e explicar cada caso em linguagem cidadã, sem nunca julgar reputação de pessoas; e (iii) avalia o LLM em múltiplas camadas — consistência contra uma rubrica determinística, e concordância contra rotulagem humana genuína (Cohen's kappa = 0,231; acurácia 40%). O achado central da avaliação é um viés de colapso do LLM: 70% dos casos foram classificados como severidade "média" e 84% como categoria "combinação", quase independentemente do sinal real — não ruído aleatório, mas uma tendência sistemática a respostas "seguras". O custo médio de classificação por caso é de US\$ 0,00525 (modelo claude-sonnet-4-6), tornando a extensão do pipeline a milhares de casos financeiramente trivial. Todo número citado neste resumo também é gerado por um chunk de código executável no corpo deste documento.

Palavras-chave: Cota Parlamentar; Detecção de Anomalias; Modelos de Linguagem; Saída Estruturada; CRISP-DM.

A Câmara dos Deputados publica diariamente os gastos da Cota para o Exercício da Atividade Parlamentar (CEAP). No recorte deste projeto (jan/2025 a jul/2026), isso soma 284,845 despesas individuais e R\$ 345,090,001.79 — volume humanamente inaudível um lançamento de cada vez. Sem uma forma de priorizar, qualquer tentativa de fiscalização manual é inviável: cidadãos, jornalistas e órgãos de controle não têm como revisar centenas de milhares de linhas para decidir onde vale a pena olhar com mais atenção.

O público-alvo deste trabalho é composto por três grupos: **cidadãos** interessados em acompanhar o uso da cota por seus representantes; **jornalistas** que precisam de pontos de partida concretos para reportagens de *accountability*; e **auditores/órgãos de controle** que já têm processo de fiscalização, mas se beneficiam de uma triagem prévia que aponte onde concentrar esforço.

O objetivo é **priorizar, não acusar**. O pipeline não determina se uma despesa é irregular — isso exige investigação humana, contexto e contraditório. O que este trabalho entrega é um ranking estatístico objetivo de casos que fogem do padrão esperado, complementado por uma camada de classificação e explicação em linguagem cidadã via LLM, sempre com saída estruturada e validada, para que a atenção limitada de quem fiscaliza seja alocada de forma mais eficiente.

1 Revisão da Literatura

O precedente direto deste trabalho, no mesmo domínio (gastos CEAP), é a **Operação Serenata de Amor** (Musskopf e Cuducos 2016): projeto open-source iniciado em 2016 por Irio Musskopf e Eduardo Cuducos que usa um robô de aprendizado de máquina (“Rosie”) para calcular uma probabilidade de irregularidade em reembolsos da Cota Parlamentar e publicar os achados. Este trabalho se diferencia em três pontos: (i) usa detecção estatística robusta (mediana/MAD) como camada auditável antes de qualquer classificação, em vez de um único score de probabilidade; (ii) usa um LLM apenas para classificar e explicar em linguagem cidadã os casos já sinalizados estatisticamente — nunca para decidir sozinho o que é atípico; e (iii) inclui triangulação entre métodos independentes e avaliação de concordância humano-LLM (Cohen’s kappa) como camada explícita de validação, ausente na Rosie original.

A camada estatística deste trabalho segue **Iglewicz & Hoaglin (1993)** (Iglewicz e Hoaglin 1993): mediana e desvio absoluto mediano (MAD) como medidas robustas de tendência central e dispersão, e o “modified z-score” (fator 0,6745) como regra prática para sinalizar outliers — escolha deliberada por ser menos sensível a caudas longas do que média/desvio padrão clássicos, um problema documentado nos próprios dados de gasto parlamentar.

Para medir concentração de gasto em fornecedor único, usamos o **Índice de Herfindahl-Hirschman (HHI)** (Hirschman 1964), originalmente uma medida de concentração de mercado em economia industrial, aqui reaproveitada para medir concentração de gasto por deputado.

Para avaliar a concordância entre a classificação do LLM e a rotulagem humana, usamos o **coeficiente kappa de Cohen** (Cohen 1960), interpretado pela escala de referência de **Landis & Koch (1977)** (Landis e Koch 1977).

A etapa de classificação por LLM segue a documentação oficial da API Anthropic para saída estruturada via Pydantic (Anthropic 2026).

2 Metodologia e Dados

2.1 Fontes e volume

Os dados vêm dos arquivos anuais públicos da Câmara (<https://www.camara.leg.br/cotas/Ano-{ano}.csv.zip>) dos anos 2025 (completo) e 2026 (parcial, até julho). Nulos concentram-se em colunas legitimamente opcionais (`txtPassageiro`/`txtTrecho`, só preenchidas em passagens aéreas) e em duas peculiaridades tratadas explicitamente na preparação dos dados: 7,191 registros com `vlrLiquido` negativo (estornos reais, mantidos na soma) e 45,635 registros sem fornecedor identificável (CNPJ genérico ou ausente, excluídos apenas do cálculo de concentração por fornecedor).

2.2 Custo estimado de tokens

A etapa de classificação por LLM tem custo medido, não estimado por analogia: usando a API de contagem de tokens da Anthropic (gratuita) sobre os prompts reais enviados e as respostas reais recebidas para os 50 casos já classificados, o custo total foi de US\$ 0.2623, ou **US\$ 0.00525 por caso** (modelo claude-sonnet-4-6, US\$ 3.0 por milhão de tokens de input e US\$ 15.0 de output). A projeção linear para os 253 casos priorizados (2 ou mais métodos convergentes) é de aproximadamente US\$ 1.33 — tornando a extensão do pipeline financeiramente trivial.

2.3 Mapeamento ao CRISP-DM

Fase CRISP-DM	Entregável neste projeto
1. Entendimento do Negócio	Problema, público-alvo e critério de sucesso (<code>reports/business_understanding.md</code>)
2. Entendimento dos Dados	Volume, tipos, nulos, custo de tokens (<code>reports/data_understanding.md</code> , acima)
3. Preparação dos Dados	Limpeza, tipagem, flags sem exclusão de linhas (<code>reports/data_preparation.md</code>)
4. Modelagem	3 detectores estatísticos + baseline determinístico + LLM com schema fixo (<code>reports/modeling.md</code>)
5. Avaliação	Sensibilidade, triangulação, LLM vs. rubrica, LLM vs. humano (<code>reports/evaluation.md</code> , <code>reports/evaluation_llm.md</code>)
6. Implantação	Lista priorizada, relatório cidadão, este paper (<code>reports/relatorio_final.md</code>)

2.4 Saída estruturada do LLM

A classificação por LLM usa um schema Pydantic fixo (`TriageAnomalia`), que força os campos `severidade` (baixa/média/alta), `categoria_anomalia`, `explicacao_cidada` (máx. 280 caracteres, sem acusação) e `perguntas_auditoria` (2 a 3 perguntas verificáveis) — ver código completo na seção Implementação. O LLM recebe apenas os casos **já** sinalizados estatisticamente; ele nunca decide sozinho o que é atípico.

2.5 Escolhas metodológicas e trade-offs

As decisões abaixo não são neutras nem inevitáveis — valem ser explicitadas, porque moldam o que o pipeline prioriza e o que deixa de fora.

Domínio: optei por CEAP em vez de gastos de saúde (DataSUS/FNS) — outro domínio de gasto público de volume comparável, citado em Próximos Passos como extensão — porque os arquivos anuais da Câmara já vêm num formato único e estável, enquanto dados de saúde exigiriam integrar múltiplas fontes antes de qualquer análise. Dado o prazo do trabalho final, priorizei entregar um pipeline completo (dado bruto → paper) a aprofundar a exploração de um domínio mais complexo de integrar.

Método de detecção: escolhi mediana + MAD (Iglewicz e Hoaglin 1993) em vez de um modelo de machine learning (ex.: isolation forest) para os três detectores de `src/model.py`. Num domínio em que o resultado associa nomes de pessoas públicas a um ranking de atenção, um método cuja decisão não é explicável em uma frase não é aceitável, mesmo que tivesse desempenho melhor em alguma métrica de detecção de anomalias. Mediana e MAD são conferíveis à mão por qualquer pessoa com uma calculadora.

Divisão de trabalho entre estatística e LLM: “o LLM nunca acusa” é uma decisão de design, não uma limitação técnica contornável. O LLM não decide o que é atípico — isso já foi decidido estatisticamente antes de qualquer prompt — e o *system prompt* de `src/llm_triage.py` proíbe explicitamente qualquer insinuação de irregularidade. O custo de um falso positivo aqui não é um erro de classificação qualquer: é o nome de uma pessoa associado a uma acusação que ela nunca cometeu.

Erro encontrado durante a exploração: a primeira implementação do filtro de CNPJ genérico comparava contra códigos de 12 dígitos em vez de 14, retornando zero registros onde na verdade existem 8.527 (ver `reports/data_understanding.md`). A correção só aconteceu porque o resultado zero era suspeito demais para aceitar sem conferir.

Rotulagem humana em duas passadas: a primeira rotulagem dos 50 casos de avaliação usou apenas o sinal de categoria×pares, um critério mais restrito do que a definição da rubrica (`reports/criterio_rotulagem.md`). A segunda passada revisou os 2 casos em que isso mudava o resultado; um deles, Bruno Ganem, permanece um caso de fronteira decidido manualmente (severidade “média”, não “alta”), porque a concentração em fornecedor de anúncios no Facebook é um padrão comum de campanha de divulgação parlamentar — um julgamento que a rubrica sozinha não captura.

3 Implementação

3.1 Configuração do ambiente

```
# Importações e leitura de chaves do ambiente (.env). NUNCA escreva a chave aqui.
import os
from pathlib import Path

import pandas as pd
from anthropic import Anthropic
```

```

from dotenv import load_dotenv
from pydantic import BaseModel, Field

load_dotenv(Path(__file__).resolve().parent / ".env")
client = Anthropic() # lê ANTHROPIC_API_KEY do ambiente

```

3.2 Coleta e preparação dos dados

O pipeline real (src/explore.py → src/prepare.py) baixa, limpa e tipa os 284.845 registros brutos sem remover nenhuma linha. O chunk abaixo carrega o resultado já processado e verificado (despesas_limpas.parquet) para confirmar as contagens citadas na Metodologia:

```

print(f"Linhas: {n_despesas:,} | Colunas: {n_colunas_raw}")
print(f"Total gasto (vlrLiquido): R$ {total_gasto:,.2f}")
print(f"Estornos (vlrLiquido < 0): {n_estornos:,}")
print(f"Sem fornecedor identificado: {n_sem_fornecedor:,}")

```

```

Linhas: 284,845 | Colunas: 37
Total gasto (vlrLiquido): R$ 345,090,001.79
Estornos (vlrLiquido < 0): 7,191
Sem fornecedor identificado: 45,635

```

3.3 Modelagem estatística (baseline)

Três detectores estatísticos independentes (src/model.py), todos baseados em mediana + MAD (score robusto, threshold 3,5) ou HHI (threshold 0,25). Servem como **baseline não-LLM** para comparação: uma rubrica determinística (src/rubric_prelabel.py) aplica os mesmos limiares sem qualquer subjetividade, e é usada na avaliação como ponto de referência de consistência para o LLM.

```

def robust_z(x: pd.Series) -> pd.Series:
    mediana = x.median()
    mad = (x - mediana).abs().median()
    escala = mad if mad > 0 else 1e-6 * (abs(mediana) + 1)
    return 0.6745 * (x - mediana) / escala

print(f"Deputados avaliados (>=1 detector): {n_deputados_total}")
print(f"Sinalizados por 2+ métodos (alta confiança): {n_alta_confianca}")
print(f"Sinalizados pelos 3 métodos simultaneamente: {n_tres_metodos}")

```

```

Deputados avaliados (>=1 detector): 601
Sinalizados por 2+ métodos (alta confiança): 253
Sinalizados pelos 3 métodos simultaneamente: 26

```

3.4 Modelagem com LLM (saída estruturada)

Schema Pydantic e chamada real de API usados em produção (src/llm_triage.py) — mostrados como código de referência (eval: false, já executado anteriormente e cujos resultados reais são carregados no chunk seguinte, para não repetir uma chamada paga):

```
from typing import Literal

class TriageAnomalia(BaseModel):
    severidade: Literal["baixa", "media", "alta"] = Field(
        description="Urgência de verificação humana, dada a magnitude e convergência dos sinais"
    )
    categoria_anomalia: Literal[
        "concentracao_fornecedor", "pico_temporal", "gasto_acima_pares", "combinacao"
    ] = Field(description="Tipo dominante do padrão detectado")
    explicacao_citada: str = Field(max_length=280, description="Linguagem simples, SEM acusação")
    perguntas_auditoria: list[str] = Field(min_length=2, max_length=3)

MAX_RETRIES = 2 # 1 tentativa + 1 retry com feedback do erro de validação

def classificar(client, caso: str) -> tuple[TriageAnomalia | None, str]:
    """Chama a API e valida com Pydantic; retry com feedback em caso de erro."""
    feedback = ""
    for tentativa in range(1, MAX_RETRIES + 1):
        resposta = client.messages.create(
            model="claude-sonnet-4-6",
            max_tokens=600,
            system=SYSTEM_PROMPT,
            messages=[{"role": "user", "content": USER_PROMPT_TEMPLATE.format(caso=caso) + feedback}],
        )
        try:
            dados = json.loads(resposta.content[0].text)
            return TriageAnomalia.model_validate(dados), f"ok_tentativa_{tentativa}"
        except Exception as e:
            feedback = f"\n\nSua resposta anterior falhou na validação: {e}. Corrija."
    return None, "nao_classificado" # falha final: registro marcado, não descartado
```

Resultado real já classificado (reports/triage_llm.csv, carregado a seguir — nenhuma chamada de API é refeita neste render):

```
print(triage["status_llm"].value_counts().to_string())
print()
print(triage["severidade"].value_counts().to_string())
```

```
status_llm
ok_tentativa_1    50
```

```
severidade
media    35
baixa    10
alta      5
```

Tabela 1

(a) Top 10 casos priorizados por número de métodos convergentes.

Deputado	Métodos (0–3)	Motivo dominante
Aguinaldo Ribeiro	3	gasto muito acima dos pares em 'PASSAGEM AÉREA - REEMBOLSO' (06/2025,
Benedita da Silva	3	gasto muito acima dos pares em 'HOSPEDAGEM ,EXCETO DO PARLAMENTAR
Bruno Ganem	3	gasto muito acima dos pares em 'ASSINATURA DE PUBLICAÇÕES' (08/2025, R.
Célio Silveira	3	gasto muito acima dos pares em 'DIVULGAÇÃO DA ATIVIDADE PARLAMENTA
Elcione Barbalho	3	gasto muito acima dos pares em 'DIVULGAÇÃO DA ATIVIDADE PARLAMENTA
Ely Santos	3	gasto muito acima dos pares em 'DIVULGAÇÃO DA ATIVIDADE PARLAMENTA
Erika Kokay	3	gasto muito acima dos pares em 'SERVIÇO DE TÁXI, PEDÁGIO E ESTACIONAM
Fabio Schiochet	3	gasto muito acima dos pares em 'HOSPEDAGEM ,EXCETO DO PARLAMENTAR
Gabriel Mota	3	gasto muito acima dos pares em 'MANUTENÇÃO DE ESCRITÓRIO DE APOIO À
Gilson Marques	3	gasto muito acima dos pares em 'HOSPEDAGEM ,EXCETO DO PARLAMENTAR

Fonte: reports/lista_priorizada.csv (src/deploy.py). Lista completa com 253 casos no arquivo original.

Tabela 2

(a) Sensibilidade do número de flags a limiares alternativos (recomputado ao vivo).

Detector	Limiar baixo	Padrão	Limiar alto
Categoria×pares (score)	1,785	1,296	1,004
Pico temporal (score)	770	582	457
Concentração fornecedor (HHI)	326	141	71

Limiares: score 3,0/3,5/4,0; HHI 0,15/0,25/0,35. Recomputado a partir dos CSVs reais de data/processed/.

Todos os 50 casos foram classificados com sucesso na primeira tentativa (`ok_tentativa_1`) — nenhum retry de validação Pydantic foi necessário.

4 Resultados

4.1 Lista priorizada

A Tabela Tabela 1a mostra os casos de maior confiança: todos com os 3 métodos estatísticos convergindo. A lista completa reduz o universo de 601 deputados para 253 sinalizados por 2 ou mais métodos — o “achado de negócio” central da fase de Modelagem/Avaliação.

4.2 Avaliação estatística: sensibilidade a limiares

A contagem cai de forma monotônica e gradual em todos os detectores (Tabela Tabela 2a) — não há salto abrupto perto do limiar padrão, indicando que a escolha de 3,5/0,25 não é um ponto artificialmente sensível.

Tabela 3

(a) Matriz de confusão: severidade (humano) vs. severidade (LLM), n=50.

Humano \ LLM	alta	media	baixa
alta	5	20	0
media	0	6	1
baixa	0	9	9

Fonte: reports/rotulos_humanos.csv
 x reports/triage_llm.csv
 (src/evaluate_llm.py), recomputado
 ao vivo.

4.3 Avaliação do LLM: rubrica vs. humano

Achado central desta avaliação: o LLM colapsa para respostas “seguras” em vez de refletir o sinal real. Comparado contra a rotulagem humana genuína (n=50), o LLM atinge apenas 40% de acurácia de severidade e **Cohen’s kappa = 0.231** (Tabela Tabela 3a) — na escala de Landis & Koch (Landis e Koch 1977), concordância “razoável”, não “substancial”. A concordância de categoria é ainda menor: 28%.

A causa não é ruído aleatório: o LLM classificou severidade “**media**” em 70% dos casos e categoria “**combinação**” em 84%, quase independentemente do valor de referência (humano ou rubrica). Contra a rubrica determinística, a acurácia cai para 24% — ainda mais baixa, porque a rubrica nunca “hesita”: ela é 100% determinística e o LLM, sem conhecer seus limiares, converge para o meio-termo aparentemente seguro.




Figura 1: Distribuição de severidade: rótulo humano vs. classificação do LLM (n=50).

A Figura 1 evidencia o colapso: a rotulagem humana se distribui de forma mais equilibrada entre as três classes, enquanto o LLM concentra a maioria absoluta em “média” independentemente do caso. **Melhoria proposta para uma próxima iteração:** injetar os limiares numéricos da rubrica diretamente no prompt do LLM (R\$ 50 mil / R\$ 10 mil / HHI 0,5 / 5+ flags / mês parcial), para que a classificação deixe de ser um julgamento qualitativo às cegas e passe a ancorar-se nos mesmos números que já orientam a rubrica determinística — sem transferir ao LLM a decisão sobre o que é atípico, apenas dando-lhe o critério explícito para classificar com mais disciplina.

4.4 Custo por caso e plano de atualização

O custo de US\$ 0.00525 por caso (medido via `count_tokens`, não estimado por analogia) torna a extensão do pipeline financeiramente trivial. **Plano de atualização:** a Câmara atualiza os dados diariamente, mas não há necessidade de reprocessar nessa frequência — uma cadência mensal ou trimestral é suficiente. Ao reprocessar, revisar se os limiares de `src/model.py` (`SCORE_THRESHOLD = 3.5`, `HHI_THRESHOLD = 0.25`) continuam adequados à luz da análise de sensibilidade (Tabela 2a), já que o volume de flags pode crescer conforme mais meses de 2026 chegam.

5 Próximos Passos

- **Injetar a rubrica no prompt do LLM:** dar ao modelo os limiares numéricos explícitos (R\$ 50 mil, R\$ 10 mil, HHI 0,5, 5+ flags, mês parcial) para reduzir o viés de colapso identificado na avaliação, sem delegar ao LLM a decisão sobre o que é atípico.
- **Extensão a gastos em saúde (DataSUS/FNS):** o mesmo pipeline estatístico (mediana/MAD, HHI, picos temporais) se aplica diretamente a repasses do Fundo Nacional de Saúde por município, outro domínio de gasto público auditável e de alto volume.
- **Automação de relatório mensal:** agendar a execução do pipeline completo (`explore` → `prepare` → `model` → `evaluate` → `deploy` → `llm_triage`) seguida da renderização deste paper, entregando uma versão atualizada sem intervenção manual.

6 Conclusão

Este trabalho entregou um pipeline CRISP-DM completo e reproduzível para priorizar despesas atípicas da Cota Parlamentar: três detectores estatísticos robustos reduzem 601 deputados a 253 casos de atenção prioritária; um LLM com saída estruturada via Pydantic classifica e explica cada caso em linguagem cidadã, a um custo de US\$ 0.00525 por caso; e uma avaliação em múltiplas camadas (sensibilidade, triangulação, rubrica determinística, rotulagem humana) mostra que o LLM ainda colapsa para respostas “seguras” ($\kappa = 0.231$, escala “razoável” e não “substancial” segundo Landis & Koch (Landis e Koch 1977)) em vez de refletir o sinal real de cada caso.

A parte estatística do pipeline (três detectores + triangulação) é reproduzível e reduz 601 deputados a 253 casos de forma auditável — isso já elimina a necessidade de revisar manualmente centenas de milhares de linhas. A classificação por LLM, por outro lado, não deveria ser usada hoje sem revisão humana da `explicacao_cidada` gerada para cada caso: um κ de 0.231 é baixo demais para tratar a saída do LLM como veredito. A próxima iteração descrita em Próximos Passos — injetar

os limiares da rubrica no prompt — ataca essa causa específica; até ela ser testada, o valor deste trabalho está na camada estatística, não na camada de linguagem.

7 Referências

Anthropic. 2026. *Anthropic API Documentation*. <https://docs.anthropic.com>.

Cohen, Jacob. 1960. “A Coefficient of Agreement for Nominal Scales”. *Educational and Psychological Measurement* 20 (1): 37–46.

Hirschman, Albert O. 1964. “The Paternity of an Index”. *The American Economic Review* 54 (5): 761–62.

Iglewicz, Boris, e David C. Hoaglin. 1993. *How to Detect and Handle Outliers*. ASQC Quality Press.

Landis, J. Richard, e Gary G. Koch. 1977. “The Measurement of Observer Agreement for Categorical Data”. *Biometrics* 33 (1): 159–74.

Musskopf, Irio, e Eduardo Cuducos. 2016. *Operação Serenata de Amor*. <https://serenata.ai/>.